

齋藤 健吾

研究背景・目的

概要

問題提起
本研究の目標

システム構成

データセットの作成
相互相関アルゴリズムによ
る開始位置合わせ
ニューラルネットワークの
学習
STFT による音声の画像化
U-net による音声強調モ
デル
誤差の定量化

研究成果

今後の研究方針

参考文献

実録音音源の原音再現を目的とした
ニューラルネットワーク型音響フィルタの研究
Development of a Deep Learning-Based Filter for
Original Sound Restoration from Real-World Audio Recordings

齋藤 健吾

有明工業高等専門学校
5 年情報システムコース

Gauthier Lovic 研究室

令和 7 年 10 月 22 日

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤 健吾

研究背景・目的

概要

問題提起

本研究の目標

システム構成

データセットの作成

相互相関アルゴリズムによる
開始位置合わせ

ニューラルネットワークの
学習

STFT による音声の画像化

U-net による音声強調モ
デル

誤差の定量化

研究成果

今後の研究方針

参考文献

① 研究背景・目的

② 概要

問題提起

本研究の目標

③ システム構成

データセットの作成

相互相関アルゴリズムによる開始位置合わせ

ニューラルネットワークの学習

STFT による音声の画像化

U-net による音声強調モデル

誤差の定量化

④ 研究成果

⑤ 今後の研究方針

⑥ 参考文献

背景

1. 実用的背景

1.1 学習教材等の録画動画 (音声) の品質向上

1.2 難聴に対する高品質な補聴技術の必要性

2. 技術的背景

2.1 簡易的な音響フィルタの限界

2.2 動的に変化するフィルタ構築の計算量の問題

目的

1. 実録音音声の原音再現技術の確立

2. 高速かつ高精度な音響フィルタの開発

背景

1. 実用的背景

- 1.1 学習教材等の録画動画 (音声) の品質向上
- 1.2 難聴に対する高品質な補聴技術の必要性

2. 技術的背景

- 2.1 簡易的な音響フィルタの限界
- 2.2 動的に変化するフィルタ構築の計算量の問題

目的

- 1. 実録音音声の原音再現技術の確立
- 2. 高速かつ高精度な音響フィルタの開発

背景

1. 実用的背景

1.1 学習教材等の録画動画 (音声) の品質向上

1.2 難聴に対する高品質な補聴技術の必要性

2. 技術的背景

2.1 簡易的な音響フィルタの限界

2.2 動的に変化するフィルタ構築の計算量の問題

目的

1. 実録音音声の原音再現技術の確立

2. 高速かつ高精度な音響フィルタの開発

概要

音源から離れた場所で録音された音には、多くのノイズや特定の周波数帯域の過度な減衰、音量全体の減衰などが見られる (Figure 1).




Figure 1: 離れた場所での実音声の録音によるノイズの混入と減衰の概略図.

概要

Figure 2 の関数 $f: x \mapsto \hat{y}$ をニューラルネットワーク (NN) で構成することを考える.




Figure 2: 本研究で作成するシステムの概略図.

全体構成

- データセットの作成

- 音源近くで録音した音声 y と、音源から離れた場所で録音した音声 x のペアを用意
- x, y は開始位置が揃っていない為、相互相関アルゴリズムを用いて一方の音声をもう一方の音声に開始位置を揃える¹

- 学習

- NN f に x を入力し、 $\hat{y} = f(x)$ を出力
- 損失関数 $L(\hat{y}, y)$ を最小化するように f のパラメータを更新

¹開始位置を揃えた後の音声も同様に x, y と表記することとする。

全体構成

- データセットの作成

- 音源近くで録音した音声 y と、音源から離れた場所で録音した音声 x のペアを用意
- x, y は開始位置が揃っていない為、相互相関アルゴリズムを用いて一方の音声をもう一方の音声に開始位置を揃える¹

- 学習

- NN f に x を入力し、 $\hat{y} = f(x)$ を出力
- 損失関数 $L(\hat{y}, y)$ を最小化するように f のパラメータを更新

¹開始位置を揃えた後の音声も同様に x, y と表記することとする。

相互相関アルゴリズム (Cross-Correlation)

相互相関関数 $R(x, y)$ は, 2 つの信号 x, y の類似度を測定するために使用される関数である.

$\text{Shift}(x, \tau)$ を, x を τ だけシフトさせた (進ませた) 信号とすると
き, 離散的な 2 つの信号の相互相関を以下の式で定義する.

齋藤 健吾

研究背景・目的

概要

問題提起

本研究の目標

システム構成

データセットの作成

相互相関アルゴリズムによ
る開始位置合わせ

ニューラルネットワークの
学習

STFT による音声の画像化

U-net による音声強調モ
デル

誤差の定量化

研究成果

今後の研究方針

参考文献

相互相関アルゴリズム (Cross-Correlation)

相互相関関数 $R(x, y)$ は、2つの信号 x, y の類似度を測定するために使用される関数である。

$\text{Shift}(x, \tau)$ を、 x を τ だけシフトさせた (進ませた) 信号とすると、離散的な 2つの信号の相互相関を以下の式で定義する²。

$$R(\text{Shift}(x, \tau), y) = \sum_{i=-\infty}^{\infty} x_{i+\tau} \cdot y_i \quad (1)$$

²添字がベクトル (配列) の範囲外を指す場合、その値は 0 とする。

相互相関アルゴリズム (Cross-Correlation)

$$R(\text{Shift}(\mathbf{x}, \tau), \mathbf{y}) = \sum_{i=-\infty}^{\infty} x_{i+\tau} \cdot y_i \quad (1)$$




Figure 3: 相互相関アルゴリズムの動作イメージ

$$R(\text{Shift}(\mathbf{x}, 1600), \mathbf{y}) = 1,000$$

相互相関アルゴリズム (Cross-Correlation)

$$R(\text{Shift}(\mathbf{x}, \tau), \mathbf{y}) = \sum_{i=-\infty}^{\infty} x_{i+\tau} \cdot y_i \quad (1)$$




Figure 3: 相互相関アルゴリズムの動作イメージ

$$R(\text{Shift}(\mathbf{x}, 800), \mathbf{y}) = 2,000$$

相互相関アルゴリズム (Cross-Correlation)

$$R(\text{Shift}(\mathbf{x}, \tau), \mathbf{y}) = \sum_{i=-\infty}^{\infty} x_{i+\tau} \cdot y_i \quad (1)$$




Figure 3: 相互相関アルゴリズムの動作イメージ

$$R(\text{Shift}(\mathbf{x}, 400), \mathbf{y}) = 5,000$$

相互相関アルゴリズム (Cross-Correlation)

$$R(\text{Shift}(\mathbf{x}, \tau), \mathbf{y}) = \sum_{i=-\infty}^{\infty} x_{i+\tau} \cdot y_i \quad (1)$$




Figure 3: 相互相関アルゴリズムの動作イメージ

$$R(\text{Shift}(\mathbf{x}, 200), \mathbf{y}) = 3,000$$

相互相関アルゴリズム (Cross-Correlation)

$$R(\text{Shift}(\mathbf{x}, \tau), \mathbf{y}) = \sum_{i=-\infty}^{\infty} x_{i+\tau} \cdot y_i \quad (1)$$




Figure 3: 相互相関アルゴリズムの動作イメージ

$$R(\text{Shift}(\mathbf{x}, 400), \mathbf{y}) = 5,000$$

相互相関アルゴリズム (Cross-Correlation)

$$R(\text{Shift}(\mathbf{x}, \tau), \mathbf{y}) = \sum_{i=-\infty}^{\infty} x_{i+\tau} \cdot y_i \quad (1)$$




Figure 3: 相互相関アルゴリズムの動作イメージ

$$R(\text{Shift}(\mathbf{x}, 400), \mathbf{y}) = 5,000 \\ = \hat{\tau}$$

相互相関アルゴリズム (Cross-Correlation)

$$R(\text{Shift}(\mathbf{x}, \tau), \mathbf{y}) = \sum_{i=-\infty}^{\infty} x_{i+\tau} \cdot y_i \quad (1)$$




Figure 3: 相互相関アルゴリズムの動作イメージ

$$\begin{aligned} R(\text{Shift}(\mathbf{x}, 400), \mathbf{y}) &= 5,000 \\ &= \hat{\tau} \\ &= \max R(\text{Shift}(\mathbf{x}, \tau), \mathbf{y}) \end{aligned}$$

相互相関アルゴリズム (Cross-Correlation)

$$R(\text{Shift}(\mathbf{x}, \tau), \mathbf{y}) = \sum_{i=-\infty}^{\infty} x_{i+\tau} \cdot y_i \quad (1)$$




Figure 3: 相互相関アルゴリズムの動作イメージ

→ $\hat{\tau} = \underset{\tau}{\operatorname{argmax}} R(\text{Shift}(\mathbf{x}, \tau), \mathbf{y})$ を得ることで, $\text{Shift}(\mathbf{x}, \hat{\tau}) \simeq \mathbf{y}$ と
るように $\mathbf{y}$ の開始位置を $\mathbf{x}$ に揃えることができる。

全体構成

- データセットの作成

- 音源近くで録音した音声 y と、音源から離れた場所で録音した音声 x のペアを用意
- x, y は開始位置が揃っていない為、相互相関アルゴリズムを用いて一方の音声をもう一方の音声に開始位置を揃える³

- ニューラルネットワークの学習

- NN f に x を入力し、 $\hat{y} = f(x)$ を出力
- 損失関数 $L(\hat{y}, y)$ を最小化するように f のパラメータを更新

³開始位置を揃えた後の音声も同様に x, y と表記することとする

ニューラルネットワークの学習

短時間フーリエ変換 (Short-Time Fourier Transform: STFT)

齋藤 健吾

研究背景・目的

概要

問題提起

本研究の目標

システム構成

データセットの作成

相互相関アルゴリズムによる
開始位置合わせ

ニューラルネットワークの
学習

STFT による音声の画像化

U-net による音声強調モ
デル

誤差の定量化

研究成果

今後の研究方針

参考文献




Figure 4: 短時間フーリエ変換 (STFT) の概略図.

音声信号を短い時間区間に分割し、各区間に対してフーリエ変換を適用することで、時間と周波数の両方の情報を得ることができる。

ニューラルネットワークの学習

短時間フーリエ変換 (Short-Time Fourier Transform: STFT)

齋藤 健吾

研究背景・目的

概要

問題提起

本研究の目標

システム構成

データセットの作成

相互相関アルゴリズムによる
開始位置合わせ

ニューラルネットワークの
学習

STFT による音声の画像化

U-net による音声強調モ
デル

誤差の定量化

研究成果

今後の研究方針

参考文献





Figure 4: 短時間フーリエ変換 (STFT) の概略図.

→ (時間-) 振幅 の 1 次元信号である音声を, (時間-) 周波数-振幅 の 2 次元の情報に変換することで, 特徴量を捉えやすくする.


ニューラルネットワークの学習

STFT による時間-周波数表現

実際に x , y に STFT を適用した例を Figure 5 に示す.



(a) 離れた位置で取得した音 x



(b) 音源近傍で取得した音 y

Figure 5: STFT による時間-周波数表現の例.

x はノイズが多く、全体的に強弱にもやがかかった様な状態であるのに対し、 y はノイズが少なく、明瞭な状態であることが分かる.

ニューラルネットワークの学習

ニューラルネットワーク (NN)




Figure 6: 本研究で用いる NN の構成例. 図は U-net アーキテクチャを示している. 図中, $\mathbf{X} = \text{STFT}(x)$, $\hat{\mathbf{y}} = \text{iSTFT}(\hat{\mathbf{Y}})$ である³.

³iSTFT は Inverse Short-Time Fourier Transform の略であり, $\mathbf{X} = \text{STFT}(x)$ ならば, $x = \text{iSTFT}(\mathbf{X}) = \text{STFT}^{-1}(\mathbf{X})$ である.

損失関数

損失関数の値が小さくなるように NN のパラメータを更新すること
で、出力 $\hat{y}$ が理想信号 y に近づくように f が構成される。

損失関数

損失関数の値が小さくなるように NN のパラメータを更新すること
で、出力 $\hat{y}$ が理想信号 y に近づくように f が構成される。

本研究では、以下の **複素スペクトル損失 (Complex Spectral Loss)**
を採用する。

$$L_{\text{CPLX}} = \frac{1}{FT} \sum_{f,t} \left| \hat{Y}_{f,t} - Y_{f,t} \right|^2 \quad (2)$$

損失関数

損失関数の値が小さくなるように NN のパラメータを更新することで、出力 $\hat{y}$ が理想信号 y に近づくように f が構成される。

本研究では、以下の **複素スペクトル損失 (Complex Spectral Loss)** を採用する。

$$L_{\text{CPLX}} = \frac{1}{FT} \sum_{f,t} \left| \hat{Y}_{f,t} - Y_{f,t} \right|^2 \quad (2)$$

この損失関数は短時間フーリエ変換 (STFT) 後の複素スペクトルを直接比較し、振幅と位相の両方の差異を最小化するものである。

研究成果

実際の x, y ペアを用いて学習させた NN に音声 x を入力した際の出力 $\hat{y}$ の例である。




Figure 7: 学習済み NN に音声 x を入力した際の出力 $\hat{y}$ の例。

- 現在完了していること
 - データセットの作成
 - 相互相関アルゴリズムの実装・評価
 - ニューラルネットワークの実装
- 今後の研究方針
 - モデルの調整・評価パイプラインの構築
 - 人の聴覚向けの損失関数の設計
 - モデルの軽量化・高速化



Y. Luo, J. Liu, and S. Ren, "Temporal Convolutional Network for Speech Bandwidth Extension," in *Proc. ICASSP*, 2023, pp. 1–5.



H. Park, S. Kim, and M. Hahn, "Speech Bandwidth Extension Based on Wasserstein Generative Adversarial Network," *IEEE Access*, vol. 9, pp. 102 345–102 357, 2021.



T. Tanaka and K. Yoshii, "Artificial Bandwidth Extension Using Conditional Variational Auto-encoders and Adversarial Learning," in *Proc. INTERSPEECH*, 2020, pp. 1416–1420.



J. Kong, J. Kim, and J. Bae, "High Fidelity Generative Adversarial Network for Bandwidth Expansion," in *Proc. NeurIPS*, 2024.



A. Mittal, K. Kumar, and M. Maiti, "Restoring Degraded Speech via Modified Diffusion Model," in *Proc. ICML*, 2021.



R. Singh and P. Pandey, "DPSNN: Spiking Neural Network for Low-Latency Streaming Speech Enhancement," in *Proc. ICASSP*, 2024, pp. 5165–5169.

実録音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤 健吾

研究背景・目的

概要

問題提起

本研究の目標

システム構成

データセットの作成

相互相関アルゴリズムによ
る開始位置合わせ

ニューラルネットワークの
学習

STFT による音声の画像化

U-net による音声強調モ
デル

誤差の定量化

研究成果

今後の研究方針

参考文献



M. Sun, T. Nguyen, and B. Raj, "STFT-Domain Neural Speech Enhancement With Very Low Algorithmic Latency," *IEEE Signal Processing Letters*, vol. 29, pp. 145–149, 2022.



Y. Macedo and B. Lee, "Low-Latency Single Channel Speech Enhancement Using U-Net CNNs," in *Proc. EUSIPCO*, 2020.



S. Pandey and D. Wang, "Real-time Noise Cancellation with Deep Learning," *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 28, pp. 1977–1986, 2020.



K. Li, Y. Chen, and Z. Wang, "Efficient Low-Latency Speech Enhancement with Mobile Deep Learning," in *Proc. ICASSP*, 2020, pp. 6404–6408.



C. K. Reddy, M. Kim, and J. H. Hansen, "Time-Frequency Masking Strategies for Single-Channel Low-Latency Speech Enhancement Using Neural Networks," in *Proc. INTERSPEECH*, 2018, pp. 3523–3527.