

実録音音源の原音再現を目的とした ニューラルネットワーク型音響フィルタの研究

齋藤 健吾[†]

[†] 有明工業高等専門学校 創造工学科 情報システムコース
Gauthier Lovic 研究室

1. 背景と目的

離れた位置での実音声の録音は、距離減衰、残響、環境雑音が同時に重畳するため、単一要因のみを仮定した補正では十分な改善が得られない。このような劣化音声は、講義録画や会議音声などの質を低下させ、その後の音声認識や文字起こし等の2次利用にも悪影響を及ぼす。そこで本研究では、音源から離れた位置で録音を行った実録音音源から、音源近傍で録音したような、原音に近い波形を再現するニューラルネットワーク型の音響フィルタを提案する。

2. 提案手法

2.1. 学習手法の概要

学習手法の分類としては教師あり学習に属し、入力音源 x と教師音源 y のペアから、函数 $f_{\text{ML}} : x \mapsto y$ を学習することを目標とする。しかしながら、手動収録データをそのまま用いると、入力 x と教師 y の開始時刻のずれが生じ、時間軸上の対応関係が崩れ、学習が困難となる。そこで本研究では、相互相関による時間軸方向の位置合わせを行い、音声の開始位置を揃えた後、特徴量として、入力を時間-周波数領域へ変換し、画像処理で広く用いられるU-Net [1] を適用、さらに逆変換で時間領域へ復元するSTFT-U-Net-iSTFT 構成の学習機構を設計した。

2.2. 相互相関による時間整列

入力 x を τ だけずらした波形と、教師 y との一致の度合いを示す相互相関 $R_{xy}(\tau)$ を

$$R_{xy}(\tau) = \sum_{i=0}^{|y|-1} x[\tau+i] y[i]$$

で定義する。相互相関 $R_{xy}(\tau)$ を最大化する τ は $\hat{\tau} = \underset{\tau}{\operatorname{argmax}} R_{xy}(\tau)$ で表され、 $\hat{\tau}$ に従って2系列をシフトし、共通区間長 L だけ切り出して学習に用いた。

2.3. STFT と U-Net によるスペクトル推定

入力波形 $x \in \mathbb{R}^L$ を短時間フーリエ変換して得た $S(x) \in \mathbb{C}^{F \times T_{\text{seg}}}$ の実部と虚部をそれぞれ1チャンネルと見なして2チャンネル化し、 $\mathbb{R}^{2 \times F \times T_{\text{seg}}}$ のテンソルとして表現した。これに加え、2チャンネル分のHilbert特徴量を加えた $X(S(x)) \in \mathbb{R}^{4 \times F \times T_{\text{seg}}} \simeq \mathbb{C}^{2 \times F \times T_{\text{seg}}}$ をニューラルネットワーク f_{ML} の入力とした。U-Net で周波数領域函数 f_{ML} を学習し、 $f_{\text{ML}}(X(S(x))) \in \mathbb{R}^{2 \times F \times T_{\text{seg}}} \simeq \mathbb{C}^{F \times T_{\text{seg}}}$ を出力とした。

2.4. 損失函数

学習を行うにあたり、損失函数 $\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) : \mathbb{R}^L \times \mathbb{R}^L \rightarrow \mathbb{R}$ を以下で定義した。

$$\begin{aligned} \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = & \|\Re S(\hat{\mathbf{y}}) - \Re S(\mathbf{y})\|_1 + \|\Im S(\hat{\mathbf{y}}) - \Im S(\mathbf{y})\|_1 \\ & + \lambda_{\log} \|\log(1 + |S(\hat{\mathbf{y}})|) - \log(1 + |S(\mathbf{y})|)\|_1 \\ & + \lambda_{\text{mag}} \||S(\hat{\mathbf{y}})| - |S(\mathbf{y})|\|_1 \\ & + \lambda_{\text{snr}} \left(-10 \log_{10} \frac{\sum_{f,t} |S(\mathbf{y})[f,t]|^2}{\sum_{f,t} (|S(\mathbf{y})[f,t]| - |S(\hat{\mathbf{y}})[f,t]|)^2} \right) \\ & + \lambda_{\text{sil}} \sum_{f,t} \exp\left(-\frac{|S(\mathbf{y})[f,t]|}{\alpha_{\text{sil}}}\right) |S(\hat{\mathbf{y}})[f,t] - S(\mathbf{y})[f,t]|. \end{aligned}$$

ここで、前5項は既存の指標を組み合わせた複素損失であり、 $\lambda_{\log}$ 、 λ_{mag} 、 λ_{snr} 、 λ_{sil} は各項の重み係数である。 λ_{sil} の係る項は教師 y が小振幅の領域ほど寄与が大きくなり、出力 $\hat{y}$ の無音区間の残留成分を抑制する無音強制項の役割を果たすよう設計した。無音強制項中、 α_{sil} は無音と認知する閾値(感度)を調整する定数である。

2.5. 逆短時間フーリエ変換 (iSTFT)

学習済みのネットワーク f_{ML} の出力から、推定波形は逆短時間フーリエ変換 $S^{\dagger} : \mathbb{C}^{F \times T_{\text{seg}}} \rightarrow \mathbb{R}^L$ により $\hat{y} = S^{\dagger}(f_{\text{ML}}(X(S(x))))$ として復元される。この一連の流れにより、入力 x から $\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}})$ を最小化することで、 $S^{\dagger}(f_{\text{ML}}(X(S(x)))) \approx y$ を達成することを目指す。

3. 実験条件

Table 1 実験条件

項目	設定
サンプルレート	44.1 kHz
学習条件	実録音 50 ペア (訓練 40/検証 10), 256 epochs
比較条件	複素損失のみ, SNR 重み付き, 無音強制項付き
評価指標	ΔE_{cplx} , ΔE_{snr} , ΔE_{sil} (いずれも改善量)

4. 結果

Table 2 検証 10 ペア平均の評価指標

比較条件	ΔE_{cplx}	$\Delta E_{\text{snr}} [\text{dB}]$	$\Delta E_{\text{sil}} [\text{dB}]$
(a) 複素損失のみ	0.637	5.17	18.01
(b) SNR 重み付き	0.586	5.17	12.88
(c) 無音強制項付き	0.617	5.24	20.02




Figure 1 各条件下での出力。横軸はサンプル数(時間)、縦軸は周波数、濃淡は振幅を表す。

Table 2 より、 ΔE_{cplx} は複素損失のみが最大を示し、スペクトル整合の観点では最も高い一緻性を示した。また、 ΔE_{snr} と ΔE_{sil} は無音強制項付き損失が最大であった一方で、SNR 重み付き損失では ΔE_{snr} の改善があまり見られなかった。Figure 1 より、(c) では、(a)、(b) に比べ、色が濃い ($\Leftrightarrow$ 振幅が小さい) 無音領域が広く分布しており、無音領域の残留成分が抑制されていることが視覚的に確認できる。

5. 結論

無音強制項の導入は、無音領域の残留成分の抑制と SNR 比の改善を促進させる上で有効であることが確認された。本手法により、全ての指標が改善されたことから、実録音音源の原音再現に有効であることが示された。

参考文献

- [1] O. Ronneberger, P. Fischer, and T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation,” *Proc. MICCAI*, pp. 234–241, 2015.