

実録音音源の原音再現を目的とした ニューラルネットワーク型音響フィルタの研究

Development of a Deep Learning-Based Filter for
Original Sound Restoration from Real-World Audio Recordings

齋藤健吾†

† 有明工業高等専門学校 創造工学科 情報システムコース
Gauthier Lovic 研究室

2026 年 2 月 18 日

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の
抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

1 背景と目的

- 研究背景
- 問題点

2 提案手法

- 時間整列
- 周波数特徴量の抽出
- モデル構成
- 損失関数

3 実験設定

- 実験条件
- 評価指標

4 結果と考察

- 定量評価
- 定性評価

5 結論

- 結論

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

背景と目的

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

背景

遠方での収音は、残響や環境ノイズの影響を受けやすい

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

背景

遠方での収音は、残響や環境ノイズの影響を受けやすい

→ 可聴性や明瞭度の低下

→ 2 次利用においても品質が劣化

背景

遠方での収音は、残響や環境ノイズの影響を受けやすい

→ 可聴性や明瞭度の低下

→ 2 次利用においても品質が劣化

帯域補正やノイズ抑制を行う音響フィルタを使用すると

実録音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フ
ィルタの研究

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の抽出

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

背景

遠方での収音は、残響や環境ノイズの影響を受けやすい

→ 可聴性や明瞭度の低下

→ 2 次利用においても品質が劣化

帯域補正やノイズ抑制を行う音響フィルタを使用すると

→ ノイズの抑制と原音存続の両立が困難

→ 帯域補正での過剰な成分強調などの副作用の懸念

背景

遠方での収音は、残響や環境ノイズの影響を受けやすい

→ 可聴性や明瞭度の低下

→ 2 次利用においても品質が劣化

帯域補正やノイズ抑制を行う音響フィルタを使用すると

→ ノイズの抑制と原音存続の両立が困難

→ 帯域補正での過剰な成分強調などの副作用の懸念

そこで...

背景

遠方での収音は、残響や環境ノイズの影響を受けやすい

→ 可聴性や明瞭度の低下

→ 2 次利用においても品質が劣化

帯域補正やノイズ抑制を行う音響フィルタを使用すると

→ ノイズの抑制と原音存続の両立が困難

→ 帯域補正での過剰な成分強調などの副作用の懸念

そこで...

ニューラルネットワークを用いて、遠方収音 x を近傍収音 y へ写すような函数 f を学習し、原音再現を目指す

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

学習データにおける問題

収音を行うと、 x と y の長さが異なり、開始位置もずれる

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

学習データにおける問題

収音を行うと、 x と y の長さが異なり、開始位置もずれる

→ 時間軸上で正しい対応関係を学習できない可能性

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

学習データにおける問題

収音を行うと、 x と y の長さが異なり、開始位置もずれる

→ 時間軸上で正しい対応関係を学習できない可能性

時間軸を揃え、 f は周波数領域での補正に専念させるべき

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

学習データにおける問題

収音を行うと、 x と y の長さが異なり、開始位置もずれる

→ 時間軸上で正しい対応関係を学習できない可能性

時間軸を揃え、 f は周波数領域での補正に専念させるべき

学習における問題

録音データ (wav) は、サンプルごとに振幅値が入った構造

学習データにおける問題

収音を行うと、 x と y の長さが異なり、開始位置もずれる

→ 時間軸上で正しい対応関係を学習できない可能性

時間軸を揃え、 f は周波数領域での補正に専念させるべき

学習における問題

録音データ (wav) は、サンプルごとに振幅値が入った構造

→ 周波数の情報が直接的に入っていない

学習データにおける問題

収音を行うと、 x と y の長さが異なり、開始位置もずれる

→ 時間軸上で正しい対応関係を学習できない可能性

時間軸を揃え、 f は周波数領域での補正に専念させるべき

学習における問題

録音データ (wav) は、サンプルごとに振幅値が入った構造

→ 周波数の情報が直接的に入っていない

→ NN は周波数の情報を自力で抽出する必要がある

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

学習データにおける問題

収音を行うと、 x と y の長さが異なり、開始位置もずれる

→ 時間軸上で正しい対応関係を学習できない可能性

時間軸を揃え、 f は周波数領域での補正に専念させるべき

学習における問題

録音データ (wav) は、サンプルごとに振幅値が入った構造

→ 周波数の情報が直接的に入っていない

→ NN は周波数の情報を自力で抽出する必要がある

周波数の情報を事前に抽出し、NN に与えるべき

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

提案手法

時間整列の必要性

問題点 1

時間軸を揃え、 f は周波数領域での補正に専念させるべき

時間整列の必要性

問題点 1

時間軸を揃え、 f は周波数領域での補正に専念させるべき

→ 相互相関を用いて、 x と y の時間整列を行う

時間整列の必要性

問題点 1

時間軸を揃え、 f は周波数領域での補正に専念させるべき

→ 相互相関を用いて、 x と y の時間整列を行う

相互相関による時間整列

信号 x を τ サンプルだけ遅延させた信号と y との一致度を相互相関 $R_{xy}(\tau)$ で定義する

$$R_{xy}(\tau) = \sum_{i=0}^{|y|-1} x[\tau + i] y[i]$$

時間整列の必要性

問題点 1

時間軸を揃え、 f は周波数領域での補正に専念させるべき

→ 相互相関を用いて、 x と y の時間整列を行う

相互相関による時間整列

信号 x を τ サンプルだけ遅延させた信号と y との一致度を相互相関 $R_{xy}(\tau)$ で定義する

$$R_{xy}(\tau) = \sum_{i=0}^{|y|-1} x[\tau + i] y[i]$$

→ $\hat{\tau} = \underset{\tau}{\operatorname{argmax}} R_{xy}(\tau)$ を用いて x と y を時間整列させる

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

共通区間長での切り出し

共通区間長 L のみを学習に用いる

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

共通区間長での切り出し

共通区間長 L のみを学習に用いる




Figure 1: 相互相関による時間整列

共通区間長での切り出し

共通区間長 L のみを学習に用いる




Figure 1: 相互相関による時間整列

→ 時間軸方向が揃い, f は周波数領域での補正に専念できる

周波数成分抽出の必要性

問題点 2

周波数の情報を事前に抽出し、NN に与えるべき

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の
抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

周波数成分抽出の必要性

問題点 2

周波数の情報を事前に抽出し、NN に与えるべき

→ 短時間フーリエ変換 (STFT) を用いて、周波数特徴を抽出

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の
抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

周波数成分抽出の必要性

問題点 2

周波数の情報を事前に抽出し，NN に与えるべき

→ 短時間フーリエ変換 (STFT) を用いて，周波数特徴を抽出

短時間フーリエ変換による周波数成分抽出

信号 x から，周波数成分を得るため，
短時間フーリエ変換 $S: \mathbb{R}^L \rightarrow \mathbb{C}^{F \times T_{\text{seg}}}$ を適用

周波数成分抽出の必要性

問題点 2

周波数の情報を事前に抽出し、NN に与えるべき

→ 短時間フーリエ変換 (STFT) を用いて、周波数特徴を抽出

短時間フーリエ変換による周波数成分抽出

信号 x から、周波数成分を得るため、
短時間フーリエ変換 $S: \mathbb{R}^L \rightarrow \mathbb{C}^{F \times T_{\text{seg}}}$ を適用

$$S(x)[f, t] = \sum_{n=0}^{N-1} x[n + tH] w[n] e^{-j2\pi f n / N}$$

短時間フーリエ変換




Figure 2: STFT 前の波形 (wav データ) $\in \mathbb{R}^L$

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の
抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

周波数特徴量の抽出

短時間フーリエ変換




Figure 2: STFT 前の波形 (wav データ) $\in \mathbb{R}^L$



Short-Time Fourier Transform

周波数特徴量の抽出

短時間フーリエ変換




Figure 2: STFT 前の波形 (wav データ) $\in \mathbb{R}^L$



Short-Time Fourier Transform




Figure 3: STFT 後のスペクトログラム $\in \mathbb{C}^{F \times T_{\text{seg}}} \simeq \mathbb{R}^{2 \times F \times T_{\text{seg}}}$

NN 入力構成 入力特徴

$$\mathbf{X}(S(\mathbf{x})) := \begin{bmatrix} \Re S(\mathbf{x}) \\ \Im S(\mathbf{x}) \\ \Re S(\mathcal{H}(\mathbf{x})) \\ \Im S(\mathcal{H}(\mathbf{x})) \end{bmatrix} \in \mathbb{R}^{4 \times F \times T_{\text{seg}}}$$

$S(\mathbf{x})$: STFT 特徴, $\mathcal{H}(S(\mathbf{x}))$: Hilbert 特徴

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失函数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

NN 入力構成 入力特徴

$$\mathbf{X}(S(\mathbf{x})) := \begin{bmatrix} \Re S(\mathbf{x}) \\ \Im S(\mathbf{x}) \\ \Re S(\mathcal{H}(\mathbf{x})) \\ \Im S(\mathcal{H}(\mathbf{x})) \end{bmatrix} \in \mathbb{R}^{4 \times F \times T_{\text{seg}}}$$

$S(\mathbf{x})$: STFT 特徴, $\mathcal{H}(S(\mathbf{x}))$: Hilbert 特徴

STFT 特徴は**周波数成分**を直接的に表し,
Hilbert 特徴は**位相の情報**を補う

NN 入力構成 入力特徴

$$\mathbf{X}(S(\mathbf{x})) := \begin{bmatrix} \Re S(\mathbf{x}) \\ \Im S(\mathbf{x}) \\ \Re S(\mathcal{H}(\mathbf{x})) \\ \Im S(\mathcal{H}(\mathbf{x})) \end{bmatrix} \in \mathbb{R}^{4 \times F \times T_{\text{seg}}}$$

$S(\mathbf{x})$: STFT 特徴, $\mathcal{H}(S(\mathbf{x}))$: Hilbert 特徴

STFT 特徴は**周波数成分**を直接的に表し,
Hilbert 特徴は**位相の情報**を補う

NN 内で特徴量を見つけ出す手間を省き, 学習を効率化

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の
抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

NN モデル

U-Net を採用




Figure 4: U-Net の構成図

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の
抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価


定性評価

結論

結論

NN モデル

U-Net を採用



ボトルネックまでは不必要なノイズを除去，以降は失われた
周波数成分を復元することが期待される。

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の
抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

NN モデル

U-Net を採用




Figure 4: U-Net の構成図

ボトルネックまでは不必要なノイズを除去，以降は失われた周波数成分を復元することが期待される。

Skip connection を用いて，Pooling により失われた周波数成分の復元を補助する。

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特微量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

損失関数の構成

$$\begin{aligned}
 \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = & \|\Re S(\hat{\mathbf{y}}) - \Re S(\mathbf{y})\|_1 + \|\Im S(\hat{\mathbf{y}}) - \Im S(\mathbf{y})\|_1 \\
 & + \lambda_{\log} \|\log(1 + |S(\hat{\mathbf{y}})|) - \log(1 + |S(\mathbf{y})|)\|_1 \\
 & + \lambda_{\text{mag}} \||S(\hat{\mathbf{y}})| - |S(\mathbf{y})|\|_1 \\
 & + \lambda_{\text{snr}} \left(-10 \log_{10} \frac{\sum_{f,t} |S(\mathbf{y})[f, t]|^2}{\sum_{f,t} (|S(\mathbf{y})[f, t]| - |S(\hat{\mathbf{y}})[f, t]|)^2} \right) \\
 & + \lambda_{\text{sil}} \sum_{f,t} \exp\left(-\frac{|S(\mathbf{y})[f, t]|}{\alpha_{\text{sil}}}\right) |S(\hat{\mathbf{y}})[f, t] - S(\mathbf{y})[f, t]|
 \end{aligned}$$

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特微量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

損失関数の構成

$$\begin{aligned}
 \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = & \|\Re S(\hat{\mathbf{y}}) - \Re S(\mathbf{y})\|_1 + \|\Im S(\hat{\mathbf{y}}) - \Im S(\mathbf{y})\|_1 \\
 & + \lambda_{\log} \|\log(1 + |S(\hat{\mathbf{y}})|) - \log(1 + |S(\mathbf{y})|)\|_1 \\
 & + \lambda_{\text{mag}} \||S(\hat{\mathbf{y}})| - |S(\mathbf{y})|\|_1 \\
 & + \lambda_{\text{snr}} \left(-10 \log_{10} \frac{\sum_{f,t} |S(\mathbf{y})[f, t]|^2}{\sum_{f,t} (|S(\mathbf{y})[f, t]| - |S(\hat{\mathbf{y}})[f, t]|)^2} \right) \\
 & + \lambda_{\text{sil}} \sum_{f,t} \exp\left(-\frac{|S(\mathbf{y})[f, t]|}{\alpha_{\text{sil}}}\right) |S(\hat{\mathbf{y}})[f, t] - S(\mathbf{y})[f, t]|
 \end{aligned}$$

複素スペクトル損失

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

損失関数の構成

$$\begin{aligned}
 \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = & \|\Re S(\hat{\mathbf{y}}) - \Re S(\mathbf{y})\|_1 + \|\Im S(\hat{\mathbf{y}}) - \Im S(\mathbf{y})\|_1 \\
 & + \lambda_{\log} \|\log(1 + |S(\hat{\mathbf{y}})|) - \log(1 + |S(\mathbf{y})|)\|_1 \\
 & + \lambda_{\text{mag}} \||S(\hat{\mathbf{y}})| - |S(\mathbf{y})|\|_1 \\
 & + \lambda_{\text{snr}} \left(-10 \log_{10} \frac{\sum_{f,t} |S(\mathbf{y})[f, t]|^2}{\sum_{f,t} (|S(\mathbf{y})[f, t]| - |S(\hat{\mathbf{y}})[f, t]|)^2} \right) \\
 & + \lambda_{\text{sil}} \sum_{f,t} \exp\left(-\frac{|S(\mathbf{y})[f, t]|}{\alpha_{\text{sil}}}\right) |S(\hat{\mathbf{y}})[f, t] - S(\mathbf{y})[f, t]|
 \end{aligned}$$

複素スペクトル損失, Log-Mag 損失

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

損失関数の構成

$$\begin{aligned}
 \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = & \|\Re S(\hat{\mathbf{y}}) - \Re S(\mathbf{y})\|_1 + \|\Im S(\hat{\mathbf{y}}) - \Im S(\mathbf{y})\|_1 \\
 & + \lambda_{\log} \|\log(1 + |S(\hat{\mathbf{y}})|) - \log(1 + |S(\mathbf{y})|)\|_1 \\
 & + \lambda_{\text{mag}} \||S(\hat{\mathbf{y}})| - |S(\mathbf{y})|\|_1 \\
 & + \lambda_{\text{snr}} \left(-10 \log_{10} \frac{\sum_{f,t} |S(\mathbf{y})[f,t]|^2}{\sum_{f,t} (|S(\mathbf{y})[f,t]| - |S(\hat{\mathbf{y}})[f,t]|)^2} \right) \\
 & + \lambda_{\text{sil}} \sum_{f,t} \exp\left(-\frac{|S(\mathbf{y})[f,t]|}{\alpha_{\text{sil}}}\right) |S(\hat{\mathbf{y}})[f,t] - S(\mathbf{y})[f,t]|
 \end{aligned}$$

複素スペクトル損失, Log-Mag 損失, SNR 損失の既存の評価指標を組み込んだ損失関数に加え,

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

損失関数の構成

$$\begin{aligned}
 \mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = & \|\Re S(\hat{\mathbf{y}}) - \Re S(\mathbf{y})\|_1 + \|\Im S(\hat{\mathbf{y}}) - \Im S(\mathbf{y})\|_1 \\
 & + \lambda_{\log} \|\log(1 + |S(\hat{\mathbf{y}})|) - \log(1 + |S(\mathbf{y})|)\|_1 \\
 & + \lambda_{\text{mag}} \||S(\hat{\mathbf{y}})| - |S(\mathbf{y})|\|_1 \\
 & + \lambda_{\text{snr}} \left(-10 \log_{10} \frac{\sum_{f,t} |S(\mathbf{y})[f,t]|^2}{\sum_{f,t} (|S(\mathbf{y})[f,t]| - |S(\hat{\mathbf{y}})[f,t]|)^2} \right) \\
 & + \lambda_{\text{sil}} \sum_{f,t} \exp\left(-\frac{|S(\mathbf{y})[f,t]|}{\alpha_{\text{sil}}}\right) |S(\hat{\mathbf{y}})[f,t] - S(\mathbf{y})[f,t]|
 \end{aligned}$$

複素スペクトル損失, Log-Mag 損失, SNR 損失の既存の評価指標を組み込んだ損失関数に加え, 無音強制項を導入

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

実験設定

Table 1: 実験条件

項目	設定
学習条件	実録音 50 ペア (訓練 40/検証 10)
Epochs	256epochs 固定
比較条件	(a) 複素損失のみ, (b) SNR 重み付き, (c) 無音強制項付き
評価指標	ΔE_{cplx} , ΔE_{snr} , ΔE_{sil}

Table 2: 各比較条件下での損失関数の重み設定

条件	$\lambda_{\log}$	λ_{mag}	λ_{snr}	λ_{sil}	α_{sil}
(a) 複素損失のみ	0	0	0	0	-
(b) SNR 重み付き	0.09	0.005	0.03	0	-
(c) 無音強制項付き	0.09	0.005	0.03	0.55	0.35

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

評価指標

ΔE_{cplx} , ΔE_{snr} , ΔE_{sil} の 3 指標で評価.

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

評価指標

ΔE_{cplx} , ΔE_{snr} , ΔE_{sil} の3指標で評価.

複素スペクトル損失改善量 ΔE_{cplx}

補正前後での複素スペクトル差の減少量.

SNR 改善量 ΔE_{snr}

補正前後での SNR の増加量 [dB].

無音領域残留低減量 ΔE_{sil}

本来無音であるべき領域に残る不要成分の減少量 [dB].

評価指標

ΔE_{cplx} , ΔE_{snr} , ΔE_{sil} の3指標で評価.

複素スペクトル損失改善量 ΔE_{cplx}

補正前後での複素スペクトル差の減少量.

SNR 改善量 ΔE_{snr}

補正前後での SNR の増加量 [dB].

無音領域残留低減量 ΔE_{sil}

本来無音であるべき領域に残る不要成分の減少量 [dB].

いずれも値が大きいほど改善を示す.

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

結果と考察

評価指標比較

Table 3: 各条件下での評価指標の比較

条件	ΔE_{cplx}	ΔE_{snr} [dB]	ΔE_{sil} [dB]
(a) 複素損失のみ	0.637	5.17	18.01
(b) SNR 重み付き	0.586	5.17	12.88
(c) 無音強制項付き	0.617	5.24	20.02

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

評価指標比較

Table 3: 各条件下での評価指標の比較

条件	ΔE_{cplx}	ΔE_{snr} [dB]	ΔE_{sil} [dB]
(a) 複素損失のみ	0.637	5.17	18.01
(b) SNR 重み付き	0.586	5.17	12.88
(c) 無音強制項付き	0.617	5.24	20.02

ΔE_{snr} と ΔE_{sil} の両方で最良

(c) 無音強制項の導入により，無音強制にとどまらず，SNR の改善にも寄与．

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価


定性評価

結論


結論

スペクトログラム比較

(a) 複素損失のみ



(b) (a) + SNR重み付き



(c) (b) + 無音強制項付き




Figure 5: 各条件下での出力スペクトログラム比較.

実録音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論

結論

本研究のまとめ

- 実録音音源の原音再現を目的として
相互相関による時間整列,
STFT-U-Net-iSTFT 構成のモデルを提案した.
- 既存の評価指標に加え, 無音領域の残留成分を抑制する
無音強制項を損失関数に導入した.
- 無音強制項付き損失が ΔE_{snr} と ΔE_{sil} の両方で最良.
全体的な復元性能を**維持・促進**させつつ,
無音区間の抑制に有効であることを確認した.

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論



M. A. Kumar and K. M. Chari, "Noise Reduction Using Modified Wiener Filter ...," *J. Intell. Syst.*, vol. 29, no. 1, 2020.



G. Ioannides and V. Rallis, "Real-Time Speech Enhancement Using Spectral Subtraction ...," arXiv:2302.10313, 2023.



D. Wang and J. Chen, "Supervised speech separation based on deep learning: An overview," *IEEE Trans. ASLP*, vol. 26, no. 10, 2018.



S. Pascual *et al.*, "SEGAN: Speech enhancement generative adversarial network," *Proc. Interspeech*, 2017.



P. Gonzalez *et al.*, "Investigating the Design Space of Diffusion Models for Speech Enhancement," *IEEE/ACM Trans. ASLP*, vol. 32, 2024.



Y. Luo and N. Mesgarani, "Conv-TasNet: Surpassing ideal time-frequency masking ...," *IEEE Trans. ASLP*, vol. 27, no. 8, 2019.



D. Stoller, S. Ewert, and S. Dixon, "Wave-U-Net ...," *Proc. ISMIR*, 2018.



A. Défossez *et al.*, "Music source separation in the waveform domain," arXiv:1911.13254, 2019.



K. Choi *et al.*, "Phase-aware speech enhancement with deep complex U-Net," *Proc. ICLR Workshop*, 2019.



Y. Hu *et al.*, "DCCRN: Deep Complex Convolution Recurrent Network ...," *Proc. Interspeech*, 2020.



D. Yin, C. Luo, and Z. Xiong, "PHASEN: A Phase-and-Harmonics-Aware Speech Enhancement Network," *Proc. AAAI*, 2020.

実録音音源の原音
再現を目的とした
ニューラルネット
ワーク型音響フィ
ルタの研究

齋藤健吾

背景と目的

研究背景

問題点

提案手法

時間整列

周波数特徴量の

抽出

モデル構成

損失関数

実験設定

実験条件

評価指標

結果と考察

定量評価

定性評価

結論

結論



J. B. Allen and L. R. Rabiner, "A unified approach to short-time Fourier analysis and synthesis," *Proc. IEEE*, vol. 65, no. 11, 1977.



O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation," *Proc. MICCAI*, 2015.



N. J. Bryan and G. J. Scavone, "Performance of CNNs for musical source separation," *Proc. ICASSP*, 2018.



A. Jansson *et al.*, "Singing Voice Separation with Deep U-Net ...," *Proc. ISMIR*, 2017.



Y. Xiao *et al.*, "On complex neural network for spectral mapping," *Proc. Interspeech*, 2019.



R. Yamamoto, E. Song, and J.-M. Kim, "Parallel WaveGAN ...multi-resolution spectrogram," *Proc. ICASSP*, 2020.



E. Vincent, R. Gribonval, and C. Févotte, "Performance measurement in blind audio source separation," *IEEE Trans. ASLP*, vol. 14, no. 4, 2006.



J. Le Roux *et al.*, "SDR – half-baked or well done?" *Proc. ICASSP*, 2019.



ITU-T Rec. P.862, "Perceptual evaluation of speech quality (PESQ)," 2001.



C. H. Taal *et al.*, "A short-time objective intelligibility measure ...," *IEEE Trans. ASLP*, vol. 19, no. 7, 2011.



J. Antoni and R. B. Randall, "Non-stationary signal processing for bearing health monitoring," *Int. J. Manuf. Res.*, vol. 1, no. 1, 2006.